

一种用于多模态的动态加权融合模型

情感分析

梁阳¹, 朱新华^{1,2,*}, 李思阳³

¹ 广西师范大学计算机科学与工程学院, 桂林 541004, 中国 ² 广西多源信息挖掘与安全重点实验室, 桂林 541004, 中国 ³ 上海智驾汽车科技有限公司, 上海 201807, 中国 * 通讯作者
: zxh429@263.net

摘要

多模态情感分析 (MSA) 任务利用文本、声学 and 视觉等多种数据源来推断用户的情感状态。以往研究主要关注捕捉不同模态间情感信息的差异性与一致性, 强调跨模态交互, 却忽视了对单一模态内部情感信息的深入挖掘。此外, 现有 MSA 方法很少探究各模态对模型性能的贡献度。针对这些问题, 本文提出一种动态加权融合的多模态情感分析模型。具体而言, 我们首先为每个单模态设计了多层级语义增强模块 (MLSE), 旨在从单模态内部多视角、多层次提取语义信息。随后, 利用遗传算法动态计算各模态的最优权重参数 $\{v^*\}$, 从而评估各模态对模型性能的影响。我们在三个基准数据集 (CMU-MOSI、CMU-MOSEI 和 CH-SIMS) 上进行了大量实验, 结果表明, 我们提出的模型在各项指标上均优于当前最先进的模型。

关键词

多模态情感分析; 多模态交互; 机器学习; 多模态融合;

1. 引言

随着信息技术和社交媒体的普及, 用户生成的数据呈现出日益多样化的特征, 为多模态情感分析提供了宝贵的资源[1]、[2]。多模态情感分析 (MSA) 融合了包括文本、听觉和视觉元素在内的多种感官模态, 以推断用户的情感和态度[3]。传统的基于文本的情感分析

主要依赖于识别文本中的情感词汇和短语来推断用户情绪[4]、[5]。然而，人类情感往往复杂多样，涉及语音语调、面部表情、手势及其他非语言线索。传统的基于文本的情感分析难以处理此类数据的复杂性，因此情感分析研究正逐渐从单模态转向多模态方法[6]。通过整合这些多样化的情感表达，多模态情感分析能够更准确、更全面地捕捉用户情绪，从而提升情感预测的可靠性和有效性。

先前的研究在多模态数据互补性探索方面取得了显著进展[7]、[8]、[9]。然而，现有的多模态情感分析研究主要聚焦于捕捉不同模态间情感信息的差异性与一致性，强调模态间的交互作用[9]、[10]，这往往以牺牲对单一模态内部情感信息的深入挖掘为代价。此外，当前的多模态情感分析方法很少探讨各模态对模型整体性能的具体贡献。当不同模态的信息存在不一致或失配时，准确有效地识别用户情感面临重大挑战[10]。例如，如图1所示，文本内容表达为“*And um while the tracker made the film look real nice and cute*”。从词语“*real nice*”和“*cute*”中可提取出积极情感，但面部表情可推断为中性甚至消极，而对应的情感标签实为负面。在这种情况下，仅依赖跨模态交互不足以弥补单一模态可能造成的信息潜在损失或误导性线索，且模态信息的不一致性为情感识别带来了复杂挑战。因此，如何有效整合多模态信息、探索各模态间的权重配比，从而更精准地识别用户情感状态，已成为亟待解决的关键问题。

针对上述多模态情感表征问题，我们提出了一种动态加权融合框架用于多模态情感分析。具体而言，我们设计了多层级语义增强模块（MLSE），该模块利用卷积神经网络[11]与多头注意力机制[12]捕捉各模态内部的抽象信息及上下文关联，从而在多个层次提升各模态的表征能力。随后，我们采用遗传算法对各模态的权重参数进行优化，最大化各模态情感特征对整体模型性能的贡献。通过遗传算法的迭代优化过程，模型能自动调整模态权重，灵活适应不同环境下模态信息的变化，计算出最

为每种模态分配合适的权重。最后，我们采用加权融合策略得出最终的情感预测结果。该方法通过深度挖掘各独立模态，在多个层次上增强了每种模态的语义信息。此外，当模态信息不一致或不匹配时，模型能够计算各模态与真实情感标签之间的相似度，动态调整各模态的权重比例及贡献度。这为多模态情感分析领域提供了创新性解决方案。我们的主要贡献可概括如下：




图1. 模态间表达的情感不一致

1. 我们设计了一个多级语义增强模块，该模块利用卷积神经网络和自注意力机制来捕捉跨模态的抽象信息和上下文关系，从而在多个层次上增强每种模态的表征能力。
2. 我们引入了一种适用于多模态情感分析的遗传算法，该算法能动态演化不同情境下各模态的权重参数，以提升情感分析的准确性与稳定性。
3. 在三个基准数据集上进行的大量实验表明，我们提出的方法相较于现有先进模型展现出更优越的性能。

2. 相关工作

2.1 多模态情感分析

近年来，多模态情感分析领域受到越来越多的关注[13]。多模态情感分析结合了来自不同感官模式的信息，如文本、语音、图像等，以推断和理解用户的情绪、态度及情感倾向[14]、[15]。相较于基于单一模式的传统情感分析方法，多模态情感分析能更全面地捕捉和理解用户的情感 $\{v^*\}$ 。

在他们的早期工作中，Zadeh等人[7]提出通过使用三重笛卡尔积运算，将所有模态信息整合到高维张量中。

以及LSTM网络[17]，但该方法计算复杂度较高。为简化这一复杂计算，Liu等人[8]提出了低秩张量融合网络（LMF），通过降低低秩张量的参数来提升数据处理效率。为加强跨模态的融合，Wang等人[18]提出了一种兼具局部融合与全局融合的分层融合网络（Raven）。该网络通过滑动窗口机制捕捉模态间的细粒度关系，同时保持计算效率。随着Transformer[12]的提出，越来越多的研究者将其应用于多模态情感分析任务。Tsai等人[19]利用定向成对跨模态注意力机制处理不同模态间的信息交互，提出了多模态Transformer（MulT）。MulT能有效处理未对齐的多模态语言序列，并学习不同模态间的关联与交互。Wang等人[20]提出的TEDT模型引入了多模态编码解码网络，以文本模态为主要信息来提升模型性能。在近期研究中，Zhang等人[21]提出ICDN模型，通过引入跨模态转换器解决时间序列对齐与模态信息缺失问题。Wang等人[22]提出文本增强转换器融合网络（TETFN），专注于学习以文本为导向的成对跨模态映射，以获得统一且鲁棒的多模态表示。Yao等人[23]提出一种多模态特征解耦策略，将情感特征划分为公共特征与私有特征（FDR-MSA），通过引入由单模态特征重建（UFR）和多模态特征重建（MFR）构成的双特征重建机制，保留解耦过程中的重要信息并减少冗余数据的影响。

2.2 模态融合策略

在多模态情感分析中，有效整合不同模态的特征至关重要[24]。当前的多模态融合策略主要分为两类：传统方法与基于深度学习的方法。如图2所示，传统方法包含早期融合与晚期融合，而基于深度学习的方法则进一步细分为基于注意力的融合与非注意力融合。

在早期融合策略中，不同模态的特征在输入层进行合并，从而简化了特征融合过程。Self-MM [25] 基于自监督学习策略设计了一个标签生成模块，将多模态情感分析任务划分为多模态任务和单模态子任务。通过对多模态和单模态任务进行联合训练，学习模态间的一致性和差异性。晚期融合，通常被称为

作为决策级融合，其过程涉及将来自不同模态的特征独立引入到其指定的模型中学习。随后，这些特定于模态的特征在模型内更高级的阶段进行整合。该方法主要涵盖平均[26]、多数投票[27]、加权求和[28]等方式。晚期融合往往缺乏对不同模态间交互信息的考量，可能导致忽略这些模态之间的互补性与相关性。基于注意力的融合策略通常利用各种注意力机制来实现模态间或模态内的信息交换。MARN[29]使用多注意力块（MAB）来发现模态间的交互，并将其存储在名为长短时混合记忆（LSTHM）的循环组件的混合记忆中。Ou等人[30]提出了一种用于情感视频内容分析的多模态局部全局注意力网络（MMLGAN），将注意力机制扩展到多级融合，并设计了一个多模态融合单元以获得情感视频的全局表示。基于注意力的方法更关注不同模态间的相关性和一致性，这可能导致模型在对不同模态特征进行加权时忽略模态间的差异。




图2. MSA模态融合策略

3. 方法论

本节首先介绍任务定义，随后详细阐述所提出的模型框架。图2展示了所提出模型的整体结构。我们将从特征提取、特征增强、权重计算及加权融合四个方面详细说明该模型。




图3. 所提出模型的整体架构

3.1 任务定义

多模态情感分析（MSA）的任务旨在通过分析多种信息模态，推断并识别用户所传达的情感极性。本研究采用的基准数据集将视频片段划分为文本（t）、音频（a）和视觉（v）信号，这些不同模态的特征信号将作为模型的输入。符号表示为 $U_m \in \mathbb{R}^{l_m \times d_m}$ ，其中 l_m 表示序列长度， d_m 表示特征维度， $m \in \{t, a, v\}$ 。相应地，模型输出情感强度结果 Y^p 。具体而言， $Y^p > 0$ 表示积极情感， $Y^p < 0$ 表示消极情感， $Y^p = 0$ 表示中性情感。

3.2 特征预处理与提取

根据先前的研究[9]、[25]，预训练的BERT[31]擅长捕捉双向上下文信息及丰富的语义关系。

在不同词汇之间，生成蕴含丰富情感信息的句子表征。因此，我们选择由12层堆叠Transformer构成的BERT模型作为文本编码器，并采用BERT最后一层的首个词向量来表征输出特征。所得文本模态的表示为

$$F_t = BERT(U_t; \theta_t^{bert}) \in \mathbb{R}^{d_t}$$

其中 U_t 代表原始文本数据， θ_{bert} 表示预训练 BERT 的所有可学习参数，而 d_t 是特征维度。

对于视觉模态，这三个数据集使用OpenFace2.0工具包[32]进行初始视频处理，包括提取面部动作单元、面部标记点和头部姿态。

视线跟踪和HOG函数[38]、[40]。最后，通过CH-SIMS[33]提取709维帧级视觉特征，通过CMU-MOSI[34]和CMU-MOSEI[35]提取35维特征。随后，我们使用LSTM网络[36]处理这三个数据集提供的预处理视觉特征 U_v 。长短期记忆网络（LSTM）是循环神经网络（RNN）[37]的一种常用变体，具有更强的记忆能力，能解决梯度消失问题，更适合处理长序列数据。我们使用LSTM最后一个时间步的隐藏状态来表示视觉模态，该状态包含整个输入序列的信息，可用于网络的最终预测或进一步处理。

$$F_v = LSTM(U_v; \theta_v^{lstm}) \in \mathbb{R}^{d_v}$$

对于音频模态，数据集CMU-MOSI和CMU-MOSEI使用语音处理工具COVAREP[39]提取特征参数，例如梅尔频率倒谱系数（MFCCs）、音量、声门源以及其他与情感和语调相关的特征。这些特征参数可通过CMU多模态SDK获取。数据集CH-SIMS使用LibROSA语音工具包[41]以默认参数在22050Hz下提取33维声学特征，这些特征与情绪和情感状态相关[42]。与视觉特征处理技术保持一致，我们也采用LSTM来提取和分析预处理后的声学特征。

$$F_a = LSTM(U_a; \theta_a^{lstm}) \in \mathbb{R}^{d_a}$$

其中 U_v 和 U_a 分别表示预处理后的音频和视觉特征， θ_m^{lstm} 代表 LSTM 中所有可学习的参数 $m \in \{v, a\}$ 。

3.3 多级语义增强融合模块

本节讨论本研究中提出的模态多级语义增强模块。在上一节的特征提取之后，我们使用

多级语义增强融合（MLSE）模块，旨在从多层次进一步强化模态特征的语义信息。具体而言，我们将前一步得到的特征 F_m 复制为三份副本。第一份保留原始形式，第二份通过一维卷积网络[11]进行处理，以增强模态的局部表征能力。Conv1D层在提取序列数据中的重要局部模式方面具有显著价值，能够灵活高效地对一维数据结构进行有效建模。接着，我们将二者拼接后送入批归一化层，这有助于提升模型性能、加速训练过程并增强模型的泛化能力。随后，经过N个线性层处理，最终获得输出。具体计算过程如公式所示：

$$F'_m = \text{Conv1D}(F_m, k_m)$$

$$F''_m = \text{BN}(F_m \oplus F'_m)$$

$$F_m^{\text{local}} = N \times \text{RELU}(\text{Linear}(F''_m); \theta_m)$$

其中 k_m 表示每个模态的核大小， $\text{BN}(\cdot)$ 表示批归一化层， θ_m 表示可学习参数， $m \in \{t, v, a\}$ 。

我们进一步利用多头注意力机制来增强第三个副本的全局语义信息。注意力机制擅长捕捉输入序列中任意两个位置（标记）之间的依赖关系，无论这两个位置之间的距离如何，这有助于模型更好地理解输入序列的全局结构和关联，

$$F_m^{\text{global}} = \text{MultiHead}(F_m, F_m, F_m) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_k) W^o$$

$$\text{head}_i = \text{Attention}(F_m W_i^q, F_m W_i^k, F_m W_i^v)$$

其中 W^o 、 W_i^q 、 W_i^k 和 W_i^v 是可学习的权重矩阵。

最后，我们使用一个门控网络来融合多层次的语义信息：

$$F_m^{\text{output}} = \text{FC}(\sigma(F_m^{\text{local}} \oplus F_m^{\text{global}}))$$

其中 $\sigma(\cdot)$ 和 FC 分别表示 sigmoid 激活函数和全连接层。




图4. 多级语义融合模块

3.4 动态权重演化

遗传算法（GA）是受生物进化启发的优化算法，
用于搜索和优化问题的解空间。

Algorithm 1 The general process of genetic algorithm

```

1: Initialize population
2: while termination condition not met do
3:   Evaluate individuals
4:   Select parents
5:   Recombine selected parents
6:   Mutate offspring
7:   Replace population with new generation
8: end while
9: return Best individual

```

Algorithm 2 The Evaluate function of genetic algorithm

```

1: function Evaluate fitness (weights, data)
2:   text data, audio data, visual data, labels  $\leftarrow$  data
3:   text score  $\leftarrow$  weights [0]  $\times$  text data
4:   audio score  $\leftarrow$  weights [1]  $\times$  audio data
5:   visual score  $\leftarrow$  weights [2]  $\times$  visual data
6:   layer  $\leftarrow$  a linear layer without bias
7:   text score, audio score, visual score  $\leftarrow$  apply layer
8:   labels  $\leftarrow$  extract numpy labels
9:   return sum of mean absolute errors between scores and labels
10: end function

```

3.5 特征融合

3.6

4. 实验

在本节中，我们通过实验评估了三种常用公共数据集模型在多模态情感分析任务中的性能。具体而言，本节重点介绍了所使用的数据集、评估指标、基线方法以及实验细节。

4.1 数据集

本研究使用了三个常用的基准数据集——CMU-MOSI [34]、CMU-MOSEI [35] 和 CH-SIMS [33]——来训练和测试我们提出的模型，这些数据集在MSA任务中被广泛使用。前两个数据集为英文，最后一个为中文。各数据集的情感类别数量如表1所示，我们已对这些数据集进行了简要介绍。

表1 MOSI、MOSEI和SIMS数据集统计信息。

Dataset	Train	Valid	Test	All
CMU-MOSI	1284	229	686	2199
CMU-MOEI	16326	1871	4659	22856
CH-SIMS	1368	456	457	2281

CMU-MOSI数据集是一个用于情感分析和情感强度预测的多模态数据集。该数据集主要包含从2199个YouTube电影评论视频中提取的93个简短独白视频片段，涵盖面部表情、语音、文本和上下文信息。每个视频片段都标注有情感标签，范围从-3（高度负面）到3（高度正面），用于表示情感倾向和强度。

CMU-MOSEI：这是CMU-MOSI的增强版本，显著扩展了其规模和范围。该数据集包含22856个带标注的视频片段，涵盖250个不同主题。此数据集与CMU-MOSI数据集具有相同的标签值。

CH-SIMS：CH-SIMS数据集是一个中文多模态情感分析数据集，共收集了来自电影、电视剧和综艺节目的60个原始视频。这些视频被分割成2281个视频片段，为每个模态提供了全面的多模态标注及独立标注。数据集集中的每个样本均被赋予一个从-1（表示强烈负面）到1（表示强烈正面）的情感得分。

4.2 基线方法

为了全面验证所提出模型的性能和有效性，我们将我们的模型与多个基线进行了比较，包括一些经典模型以及最新的最先进模型。我们比较的模型如下：

MuT [19] (2019): 多模态 Transformer (MuT) 利用定向成对跨模态注意力来捕捉不同模态之间的相关性，增强不同模态间的交互，从而获得更丰富的多模态特征表示。

ICCN [43] (2019)：交互典型相关网络 (ICCN) 通过深度典型相关分析 (DCCA) 学习所有三种模态之间的相关性，以实现文本与音频、文本与视频之间的深度关联。

MAG-BERT [44] (2020)：该模型提出将Bert与XLNet [45]的核心架构与多模态适配门相结合，并利用非语言模态信息来调整语言模态。

MISA [9] (2020): 模态不变与模态特定表示 (MISA) 将每种模态划分为模态不变子空间和模态特定子空间，并学习各子空间的模态表示，为多模态数据提供了全面的视角。

Self-MM [25] (2021)：该模型利用自监督多任务学习来获取单模态标签，实现了多模态与单模态任务的联合训练，有助于学习模态间的一致性与差异。

MMIM [46] (2021年)：多模态信息调制 (MMIM) 首次将信息最大化引入多模态情感分析任务，通过分层互信息最大化框架，增强输入单模态对之间以及多模态融合结果与单模态输入之间的互信息。

HYCON [47] (2023)：该方法提出了一种基于对比学习的多模态表示学习框架，设计了三种损失函数，以有监督和无监督的方式全面学习模态间与模态内的动态关系。

SIMR [48] (2023年)：说话人无关的多模态表示 (SIMR) 框架将非语言表示分解为个人风格编码和情感表示，以减轻个人风格的影响，并利用增强的跨模态转换器来探索模态间的上下文交互。

MUTA-Net (2023): 该模态话语时序注意力网络将话语级表征应用于不同模态间的交互，通过最小化类内距离与最大化类间距离，增强了表征的判别力。

TETFN [22] (2023) : 文本增强型Transformer融合网络 (TETFN) 通过基于文本学习成对的跨模态映射, 获得有效的统一多模态表示, 并借助单模态标签关注模态差异。

AOBERT (Kim & Park, 2023) 在单一BERT网络中整合所有模态, 通过单流Transformer集成三种类型的模态表示, 并利用多模态表示训练MMLM和AP任务。

ALMT [43] (2023) : 自适应语言引导多模态转换器 (ALMT) 引入了自适应超模态学习 (AHL) 模块, 旨在语言特征的引导下学习视觉与听觉特征中包含的无关及冲突信息, 从而获得互补且联合的多模态表征。

DMD (2023) : 解耦多模态蒸馏 (DMD) 通过预处理和提取不同模态信息的特征, 利用知识蒸馏技术在不同模态间传递和融合知识

MCR [47] (2023): MCR 方法从人类感知范式中汲取灵感, 提出了一种针对目标与源模式的协作强化方法。该方法旨在促进跨模态在不同细节层次上进行有效的交互与融合。

TMBL [41] (2024) : 一种基于Transformer的多模态绑定与学习模型 (TMBL) 融合了双模态与三模态绑定机制、细粒度卷积模块, 并利用相似性与相异性损失来促进模型收敛。

4.3 实验参数

我们进行了大量实验以研究超参数和学习策略的影响, 从而确定最优设置。我们采用Adam优化器 (Kingma & Ba, 2015), 初始学习率为 $5^e - 5$ 来优化可训练参数。考虑到计算资源和训练效率, 我们将批量大小设置为32。特别地, 训练过程中采用了早停策略, 即若验证损失连续8个轮次未下降, 则终止训练过程。本文提出的模型基于Python 3.9和Python 1.4.0实现。所有实验均在Windows 10操作系统下使用单张GeForce RTX 4090 (24G) GPU完成。预训练的BERT模型可从Hugging Face发布的Transformer工具包中获取。训练过程中的超参数设置如表2所示。

4.4 评估指标

本研究采用五种不同的指标来衡量所提出模型的实验性能：MAE（平均绝对误差）直接计算真实标签与模型预测标签之间的误差；Corr（皮尔逊相关系数）衡量预测偏差的程度。Acc7（七分类准确率：情感标签介于[-3,3]之间）用于情感评分分类任务；Acc2（二分类准确率：正面/负面情感）和F1分数用于二分类情感分类任务。除MAE外，其他指标值越高表示模型性能越好。这些指标的计算公式如下：

5. 结果与分析

5.1 定量分析

表2 在 CMU-MOSEI 上与先前模型的性能比较。“-”：原始论文中未提供。所有结果均摘自原始论文。带 * 的结果为在相同条件下复现所得。前三名结果以粗体标出，最佳结果额外添加下划线。在 Acc-2 与 F1-Score 中，“/”左侧按“负面/非负面”计算，右侧按“负面/正面”计算。

Models	MAE (↓)	Acc-2 (↑)	F1-score(↑)	Acc-7 (↑)	Corr (↑)
MuT o	0.871	- / 83.0	- / 82.8	40.0	0.698
ICCN o	0.862	- / 83.07	- / 83.02	39.01	0.714
MAG-BERT*	0.727	82.37 / 84.43	82.50 / 84.61	43.62	0.781
MISA o	0.783	81.8 / 83.4	81.7 / 83.6	42.3	0.761
Self-MM o	0.713	84.0 / 85.98	84.42 / 85.95	-	0.798
MMIM*	0.755	83.67 / 85.37	83.62 / 85.37	45.34	0.773
HYCON o	0.713	- / 85.2	- / 85.1	46.6	0.790
SIMR o	0.706	84.2 / 86.1	84.0 / 86.1	48.2	0.798
MUTA-Net o	0.730	83.1 / 85.0	83.0 / 85.0	-	0.793
TETFN o (2023)	0.717	84.05/86.10	83.83/86.07	-	0.800
AOBERT o	0.856	85.2 / 85.6	85.4 / 86.4	40.2	0.700
ALMT*	0.720	82.94 / 84.91	83.07 / 84.97	47.08	0.783
DMD*	0.736	- / 85.4	- / 85.4	46.34	0.784
MCR o	0.824	- / 84.8	- / 84.6	42.6	0.735
TMBL o	0.867	81.78/83.84	82.41/84.29	36.3	0.762
Ours	0.695	84.84/86.69	84.83/86.72	48.52	0.810

表3 在CMU-MOSEI上与先前模型的性能比较。“-”：未在

原始论文。所有结果均报告于原始论文中。带 * 的结果是在相同条件下复现的。前三名结果以**粗体**突出显示，最佳结果额外添加下划线。在 Acc-2 和 F1-Score 中，“/” 左侧按 “负面/非负面” 计算，右侧按 “负面/正面” 计算。

Models	MAE (↓)	Acc-2 (↑)	F1-score(↑)	Acc-7 (↑)	Corr (↑)
MuT o	0.580	- / 82.5	- / 82.3	51.8	0.703
ICCN o	0.565	- / 84.18	- / 84.15	51.58	0.713
MAG-BERT*	0.543	82.5 / 84.82	82.77 / 84.71	52.67	0.755
MISA o	0.555	83.6 / 85.5	83.8 / 85.3	52.2	0.756
Self-MM o	0.530	82.81 / 85.17	82.53 / 85.30	-	0.765
MMIM*	0.543	83.08 / 85.04	83.48 / 84.88	45.34	0.758
HYCON o	0.601	- / 85.4	- / 85.6	52.8	0.776
SIMR o	0.580	82.5 / 82.9	81.9 / 82.9	52.6	0.696
MUTA-Net o	0.544	82.4 / 85.0	82.7 / 84.9	-	0.760
TETFN o (2023)	0.551	84.25 / 85.18	84.18 / 85.27	-	0.748
AOBERT o	0.515	84.9 / 86.2	85.0 / 85.9	54.5	0.763
ALMT*	0.533	82.23 / 85.66	81.89 / 85.79	52.82	0.777
DMD*	0.541	- / 85.5	- / 85.4	52.5	0.762
MCR o	0.554	- / 84.7	- / 84.3	54.5	0.736
TMBL o	0.545	84.23/85.84	84.87/85.92	52.4	0.766
Ours	0.526	83.69/85.97	83.86/85.98	54.8	0.768

5.2 消融研究

结论

本文提出了一种多模态情感分析模型，该模型融合了三种融合方法，适用于多模态情感分析任务。该模型结合了早期融合和模型级融合的优势，通过多类型、多层次的融合方式，获取模态间强大的跨模态关联特征。在CMU-MOSI和CMU-MOSEI数据集上的大量实验表明，该模型在多模态情感分析任务中优于其他方法。经验表明，文本特征通常优于非文本特征。

未来的工作中，我们将进一步探索强特征和弱特征在多模态情感分析任务中的贡献。

利益冲突

作者声明，对于本论文所报道的工作，不存在任何已知的可能影响研究结果的竞争性经济利益或个人关系。

作者贡献声明

梁阳：概念化、方法论、软件、形式分析、初稿撰写。朱新华：数据管理、监督、资金获取、文稿审阅与编辑。李思洋：调查、资源、项目管理。

数据使用的伦理和知情同意

本研究使用的数据集为卡内基梅隆大学研究人员创建的CMU-MOSI与CMU-MOSEI。这些数据集公开可用，专为多模态情感分析领域的学术研究设计，不包含任何个人身份信息或敏感数据。其使用符合相应发布方规定的条款与条件。由于数据来源于不涉及人类受试者信息的公开渠道，本研究无需获取特定知情同意。这些数据源面向研究目的开放，且经过匿名化处理以充分保障个人隐私。

数据可用性与访问

当前研究中使用和分析的数据集可从通讯作者处获取。

致谢

本工作部分得到了国家自然科学基金（项目编号：62062012）和广西多源信息集成与智能处理协同创新中心的支持。

参考

[1] Kaur, R. & Kautish, S. (2019). 多模态情感分析：综述与比较. *International Journal of Service Science, Management, Engineering, and Technology (IJSSMET)*, 10(2), 38-58. <http://doi.org/10.4018/IJSSMET.2019040103>.

[2] Zhu, L., Zhu, Z., Zhang, C., Xu, Y., & Kong, X. (2023). 基于融合方法的多模态情感分析综述. *Information Fusion*. [3] Soleymani, Mohammad, Garcia, David, Jou, & Brendan, et al. (2017). 多模态情感分析综述. *Image & Vision Computing*. <http://doi.org/10.1016/j.imavis.2017.08.003>.

[4] Bakshi, R. K., Kaur, N., Kaur, R., & Kaur, G. (2016). 观点挖掘与情感分析。计算机科学与工程系, Guru Tegh Bahadur 技术学院, G-8 区, Rajouri Garden, 新德里-110064, 印度。 [5] Guo, X., Yu, W., & Wang, X. (2021). 细粒度文本情感分析综述: 调查与挑战。物理学报会议系列, 1757(1), 012038。 <http://doi.org/10.1088/1742-6596/1757/1/012038>. [6] Zhang, L., Wang, S., & Liu, B. (2018). 深度学习用于情感分析: 综述。Wiley 跨学科评论: 数据挖掘与知识发现, e1253。 <http://doi.org/10.1002/widm.1253> [7] Zadeh, A., Chen, M., Poria, S., Cambria, E., & Morency, L. P. (2017). 用于多模态情感分析的张量融合网络, 收录于: 2017年自然语言处理经验方法会议论文集。 <http://doi.org/10.18653/v1/D17-1115>.

[8] 刘, Z., 沈, Y., Lakshminarasimhan, V. B., 梁, P. P., Zadeh, A., & Morency, L. P. (2018). 使用模态特定因子的高效低秩多模态融合。 <http://doi.org/10.18653/v1/P18-1209>

[9] Hazarika, D., Zimmermann, R., & Poria, S. (2020). MISA: 面向多模态情感分析的模态不变与模态特定表示。载于: 第28届ACM国际多媒体会议论文集, 2020年, 第1122-1131页。 [10] Zhang, L., Jin, L., Xu, G., Li, X., Xu, C., Wei, K., Liu, N., & Liu, H. (2024). CAMEL: 通过上下文解耦捕获隐喻对齐以实现多模态情绪识别。AAAI人工智能会议论文集, 38(8), 9341-9349. <https://doi.org/10.1609/aaai.v38i8.28787> [11] S. Bai, J. Z. Kolter, V. Koltun. (2018). 通用卷积与循环网络用于序列建模的实证评估。 <https://doi.org/10.48550/arXiv.1803.01271> [12] Vaswani, A., Shazeer, N. M., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. 神经信息处理系统。 [13] Chandrasekaran G, Nguyen T N, Jude H D. 面向社交媒体应用的多模态情感分析: 一项全面综述。Wiley 跨学科评论: 数据挖掘与知识发现 [2024-05-11]. <https://10.1002/widm.1415>.

[14] Ananya Pandey, Dinesh Kumar Vishwakarma. 基于深度学习的多模态情感分析进展、成就与挑战：综述. *Applied Soft Computing*, Volume 152, 2024, 111206. <http://doi.org/10.1016/j.asoc.2023.111206>

[15] Zhu, T., Li, L., Yang, J., Zhao, S., Liu, H. 等人. (2022). 基于图文交互网络的多模态情感分析. *IEEE Transactions on Multimedia*, 25, 3375–3385.

[16] Lai S., Hu X., Xu H., Ren Z., & Liu Z. (2023). 多模态情感分析：综述, 《Displays》, 第80卷, 2023年, 102563页, ISSN 0141-9382, <https://doi.org/10.1016/j.displa.2023.102563>.

[17] Malhotra, P., Vig, L., Shroff, G., & Agarwal, P. (2015). 用于时间序列异常检测的长短期记忆网络. 第23届欧洲人工神经网络、计算智能与机器学习研讨会, E SANN 2015. [18] Wang, Y., Shen, Y., Liu, Z., Liang, P. P., Zadeh, A., & Morency, L.-P. (2019). 词语可迁移：利用非言语行为动态调整词表示. *AAAI人工智能会议论文集*, 33(01), 7216-7223. <https://doi.org/10.1609/aaai.v33i01.33017216>

[19] Tsai, Y. H. H., Bai, S., Liang, P. P., Kolter, J. Z., & Salakhutdinov, R. (2019). 用于非对齐多模态语言序列的多模态Transformer, 收录于：第57届计算语言学协会年会论文集, 第6558–6569页. <https://doi.org/10.18653/v1/P19-1656>

[20] Wang, F., Tian, S., Yu, L. 等. TEDT：基于Transformer编码-解码翻译网络的多模态情感分析. *Cogn Comput* 15, 289–303 (2023). <https://doi.org/10.1007/s12559-022-10073-9>

[21] 张, Q., 石, L., 刘, P., 朱, Z., & 徐, L. (2023). ICDN：基于Transformer融合一致性与差异性网络的多模态情感分析. *Applied Intelligence*. <https://doi.org/10.1007/s10489-023-04869-x>

[22] 王 D., 郭 X., 田 Y., 刘 J., 何 L., & 罗 X. (2023). TETFN：一种用于多模态情感分析的文本增强型Transformer融合网络. *模式识别*, 第136卷, 2023年, 109259, ISSN 0031-3203. <https://doi.org/10.1016/j.patcog.2022.109259>.

[23] 傅 Y., 黄 B., 温 Y., & 张 P. (2024). FDR-MSA：通过特征解耦与

重建。基于知识的系统, 第297卷, 2024年, 111965, ISSN 0950-7051。 <https://doi.org/10.1016/j.knosys.2024.111965>。

[24] 李, Y., 张, K., 王, J., & 高, X. (2020). 一种基于注意力神经网络的认知脑模型用于多模态情感分析. 神经计算, 430(2). <https://doi.org/10.1016/j.neucom.2020.10.021>[25] 余, W., 徐, H., 袁, Z., & 吴, J. (2021). 通过自监督多任务学习学习模态特定表示以进行多模态情感分析. AAAI人工智能会议论文集, 35(12), 1079 0-10797. <https://doi.org/10.1609/aaai.v35i12.17289>

[26] Shutova, E., Kiela, D., & Maillard, J. (2016). 黑洞与白兔: 利用视觉特征进行隐喻识别. 北美计算语言学协会人类语言技术分会会议. <https://doi.org/10.18653/v1/N16-1020>

[27] Morvant, E., Habrard, A., Ayache, S. (2014). 用于晚期融合的多样化分类器多数投票. 载于: Fränti, P., Brown, G., Loog, M., Escolano, F., Pelillo, M. (编) 结构、句法与统计模式识别. S+SSPR 2014. 计算机科学讲义, 卷 8621. Springer, Berlin, Heidelberg. https://doi.org/10.1007/978-3-662-44415-3_16[28] Evangelopoulos, G., Zlatintsi, A., Potamianos, A., Maragos, P. A., Rapantzikos, K. E., & Skoumas, G., 等. (2013). 基于听觉、视觉和文本注意力的多模态显著性与融合用于电影摘要生成. IEEE多媒体汇刊, 第1553-1568页。[29] Zadeh, A., Liang, P. P., Poria, S., Vij, P., & Morency, L. P. (2018). 用于人类交流理解的多注意力循环网络. 人工智能AAAI会议论文集, 2018. <https://doi.org/10.48550/arXiv.1802.00923>[30] Ou Y., Chen Z., & Wu F. (2021). 用于情感视频内容分析的多模态局部-全局注意力网络, 载于IEEE电路与系统视频技术汇刊, 卷31, 第5期, 第1901-1914页, 2021年5月。 <https://doi.org/10.1109/TCSVT.2020.3014889>[31] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). Bert: 用于语言理解的深度双向Transformer预训练, 载于: NaacL-HLT会议论文集, 卷1, 2019年, 第2页。

[32] Baltrusaitis, T., Zadeh, A., Lim, Y. C., & Morency, L. P. (2018). OpenFace 2.0: 面部行为分析工具包。IEEE 自动人脸与手势识别国际会议 (pp.59-66). IEEE 计算机学会。[33] Yu, W., Xu, H., Meng, F., Zhu, Y., & Yang, K. (2020). CH-SIMS: 一个带有细粒度模态标注的中文多模态情感分析数据集。第58届计算语言学协会年会论文集。 <https://doi.org/10.18653/v1/2020.acl-main.343>[34] Zadeh, A., Zellers, R., Pincus, E., & Morency, L. P. (2016). 视频中的多模态情感强度分析: 面部表情与言语信息。IEEE 智能系统, 31(6), 82-88。 <https://doi.org/10.1109/MIS.2016.94>[35] Zadeh A., Liang P.P., Poria S., Cambria E., & Morency L.-P. (2018) 真实环境下的多模态语言分析: CMU-MOSEI 数据集与可解释动态融合图, 载于: 第56届计算语言学协会年会论文集。 <https://doi.org/10.18653/v1/P18-1208>[36] Hochreiter, S., & Schmidhuber, J. (1997). 长短期记忆。神经计算, 9(8), 1735-1780。 <https://doi.org/10.1162/neco.1997.9.8.1735>[37] Jürgen Schmidhuber. (2015). 神经网络中的深度学习: 综述。神经网络, 61, 85-117。[38] Dalal, N., & Triggs, B. (2005). 用于人体检测的定向梯度直方图。IEEE 计算机学会计算机视觉与模式识别会议。IEEE。[39] Degottex, G., Kane, J., Drugman, T., Raitio, T., & Scherer, S. (2014). COVAR EP: 一个用于语音技术的协作语音分析库。2014年IEEE声学、语音与信号处理国际会议。IEEE。[40] Chen L., Zhao Y., Chan J.C.-W., & Kong S.G. (2022) 用于快照光谱图像描述的定向马赛克梯度直方图。ISPRS 摄影测量与遥感杂志, 183 (2022), pp. 79-93。 <https://doi.org/10.1016/j.isprsjprs.2021.10.018>[41] Mcfee, B., Raffel, C., Liang, D., Ellis, D., & Nieto, O. (2015). Librosa: Python中的音频与音乐信号分析, 载于: 第14届Python科学会议论文集, 第8卷。[42] Li, R., Wu, Z., Jia, J., Li, J., Chen, W., & Meng, H. (2018). 在真实人机会话对话中推断用户情感状态变化。2018年ACM多媒体会议, 第136-144页。ACM。

[43] 孙振、P. Sarma、W. Sethares、梁勇. (2019). 通过深度典型相关学习文本、音频和视频之间的关系以进行多模态语言分析, 收录于: 《AAAI人工智能会议论文集》, 第1卷, 2019年, 第2236–2246页。 [44] W. Rahman, M.K. Hasan, S. Lee, A. Zadeh, C. Mao, L.-P. Morency, E. Hoque, 在大型预训练Transformer中集成多模态信息, 收录于: 《计算语言学协会会议论文集》, 2020年, 第2359页。 <https://doi.org/10.48550/arXiv.1908.05787> [45] Yang, Z., Dai, Z., Yang, Y., Carbonell, J., Salakhutdinov, R., & Le, Q. V. (2019). XLNet: 用于语言理解的广义自回归预训练。 <https://doi.org/10.48550/arXiv.1906.08237> [46] 韩伟、陈浩、Poria, S. (2021). 通过层次化互信息最大化改进多模态融合以进行多模态情感分析, 收录于: 《2021年自然语言处理实证方法会议论文集》, 2021年, 第9180–9192页。 <https://doi.org/10.48550/arXiv.2109.00412> [47] 麦松、曾毅、郑帅、胡海. (2023). 用于多模态情感分析的三模态表征混合对比学习。《IEEE情感计算汇刊》, 14(3), 2276–2289. [48] 王健、王帅、林敏、徐震、郭伟. (2023). 学习说话人无关的多模态表征以进行情感分析。《信息科学: 国际期刊》。 <https://doi.org/10.1016/j.ins.2023.01.116> [49] 唐震、肖强、周星、李阳、陈晨、李科. (2023). 学习判别性多关系表征以进行多模态情感分析。《信息科学》, 第641卷, 2023年, 119125页, ISSN 0020-0255。 <https://doi.org/10.1016/j.ins.2023.119125>. [50] s
